Memoria Práctica 1: Seguimiento de un vehículo en la ciudad de Robobo

Miguel Armesto Dapena y Pablo Fariña Clemente

1. Definición del espacio de observación, espacio de acción, función de recompensa, condición de terminación y truncamiento y reinicio de los episodios:

- **Espacio de observación:** A la hora de definir el espacio de observación tuvimos en cuenta qué podría utilizar el robobo para poder realizar el aprendizaje y una posterior evaluación correctamente. Para ello en un principio optamos por usar los sensores IR y la cámara. Los sensores IR serían claves puesto que nos ayudan a detectar choques con elementos del mundo como señales de tráfico o edificios y la cámara es un elemento esencial puesto que nos ayuda a detectar el blob, de esta manera podemos medir que tan centrado está este y que tan alejado está usando el tamaño del mismo. Una vez empezamos con los entrenamientos decidimos implementar los dos sensores IR laterales a mayores de los 3 centrales que usábamos antes, esto se debe a que durante los entrenamientos pudimos notar choques recurrentes debido a que en ciertos ángulos el robobo no podía detectar obstáculos. A mayores, una vez que entrenamos decidimos aumentar el espacio de acciones para minimizar los giros innecesarios del robot, de esta forma añadimos la última posición conocida del blob y el tiempo que lleva sin ver al blob. Por último, también observamos tanto la velocidad angular como lineal del robot para poder controlar qué tan rápido y cómo gira.

- **Espacio de acción:** el espacio de acción es mucho más simple pues se limita a dos acciones: el control de la velocidad angular y el control de la velocidad lineal que, como ya describí antes, sirven tanto como para avanzar en línea recta o girar.

- **Función de recompensa:** en un principio nuestra función de recompensa consistía en la suma de la distancia del blob al centro de la cámara y la diferencia entre el tamaño del blob y el tamaño ideal del blob, de esta manera podíamos controlar que el robobo mantuviese una distancia razonable con el guía y que lo mantuviese en el centro. Sin embargo de esta forma el robobo oscilaba demasiado y no se mantenía en el carril, además, esta recompensa premiaba los episodios cortos así que el robot tendía a aprender a perder el blob al inicio de los episodios. Por esta razón debimos cambiar la función para que el robobo fuese recompensado por tener la pelota en su visión y además fuese penalizado cuando la perdiese. También se añadieron otras penalizaciones relacionadas con los giros bruscos, los movimientos en zigzag y giros demasiado pronunciados para evitar que el robot pudiese salirse del carril. La última penalización se activa

cuando ha habido una condición de reinicio. La recompensa es una suma de todos estos valores siendo las penalizaciones valores negativos y los premios valores positivos.

Término	**Expresión**	**Magnitud observable**	**Coeficiente**
Pelota visible	+c	Visibilidad	c = 0,2
Centrado	$c \cdot \exp(-(ex/\sigma)^2)$	Error horizontal ex	c = 0,5; σ = 0,6
Tamaño	$c \cdot \exp(-((t - t^*)/\sigma)^2)$	Tamaño del blob t	c = 0,3; σ = 0,1; t* = 0,20
Pelota perdida	−c por paso sin verla	Visibilidad	c = 0,2
Giro brusco	$-c \cdot \lvert \Delta\omega \rvert / \Delta\omega_máx$	Velocidad angular	c = 0,05
Zigzag	−c si ω cambia de signo	Velocidad angular	c = 0,3
Giro excesivo	$-c \cdot \lvert \omega \rvert / \omega_máx$	Velocidad angular	c = 0,05
Fallo	−c al terminar por fallo	Visibilidad, IR, tamaño	c = 30

- **Condición de terminación y truncamiento:** para las condiciones de terminación consideramos que el episodio se debería terminar si se pasan más de 3s sin encontrar el blob, el blob es demasiado grande por lo que hay riesgo de choque con el robot guía o si la proximidad con algún objeto es demasiado grande. En cuanto al truncamiento decidimos calcular el número máximo de pasos basándonos en los segundos que queríamos para cada episodio. Cada paso se basa en esperar a una nueva detección de los blobs por lo que hemos fijado esta espera en 0.2s y haciendo una división de los segundos máximos entre segundo por paso podemos obtener el número de pasos totales que usamos para nuestros algoritmos.

- **Reinicio de los episodios:** los episodios se reinician cuando suceden las anteriores condiciones, al inicio de cada episodio el robobo espera unos segundos para poder darle tiempo al robot guía de colocar su pan y prepararse para avanzar.

2. Pruebas realizadas

2.1. Condiciones comunes de los entrenamientos

Todos los entrenamientos que se presentan comparten el mismo entorno, la misma función de recompensa y la misma configuración del guía. Se entrenó con el guía en modo variable, con velocidades entre 10 y 40, lo mismo se usa en la evaluación. Cada entrenamiento dura 200 episodios completos, controlados por un callback que detiene el aprendizaje al alcanzar esa cifra.

El paso del entorno se compone de una espera de 0,2 s para que la acción surta efecto y de la espera de un mensaje de blobs y uno de infrarrojos posteriores a ese instante. Como el detector de blobs publica a

5 Hz, la duración real medida del paso es de unos 0,4 s, calculada a partir del tiempo de reloj y del número de pasos registrados. A esto se suman unos 8–9 s por reinicio, de los que 7 s son la espera para que el guía arranque. El truncamiento fue de 120 s (600 pasos) en el entrenamiento de la semilla 2026 y de 45 s (225 pasos) en el de la semilla 2027.

Durante el entrenamiento con SAC, los cinco primeros pasos de cada episodio son una acción de arranque fija (avance recto a velocidad máxima reducida), que se guarda en el buffer como la acción realmente ejecutada. En la evaluación esta demostración se desactiva.

Tabla 1. Hiperparámetros de los algoritmos. En SAC se cambiaron respecto a Stable-Baselines3 el buffer (50 000 frente a 10^6, suficiente para 200 episodios), el lote (128 frente a 256) y learning_starts (250 frente a 100). En PPO se redujo n_steps de 2048 a 512, para actualizar la política con más frecuencia.

Parámetro	SAC	PPO
Política	MlpPolicy	MlpPolicy
Tasa de aprendizaje	$3 \cdot 10^{-4}$	$3 \cdot 10^{-4}$
γ	0,99	0,99
Tamaño de lote	128	64
Buffer de repetición	50 000 transiciones	—
learning_starts	250 pasos	—
τ (actualización suave)	0,005	—
Frecuencia de entrenamiento	1 actualización por paso	10 épocas cada 512 pasos
Coeficiente de entropía	automático	—
Semillas	2026, 2027	2026

Como referencia de una política aleatoria en el propio entorno de entrenamiento se toman los 8 primeros episodios del entrenamiento SAC con semilla 2027. Corresponden a los 171 primeros pasos, anteriores a learning_starts, en los que SAC ejecuta acciones uniformes en el espacio de acción. Su recompensa media es de −27,1 por episodio, con unos 21 pasos de duración: la política aleatoria pierde el blob a los pocos segundos y el episodio termina con la penalización de fallo (−30).

2.2. Evolución del diseño del entorno

El entorno final es el resultado de varias iteraciones guiadas por la observación de los episodios en el simulador. No se conservaron los modelos ni los registros de las versiones intermedias, por lo que esta evolución no se acompaña de curvas comparativas. Las curvas de los apartados siguientes corresponden únicamente a la versión final.

2.3. Entrenamiento con SAC

SAC supera la referencia aleatoria desde los primeros miles de pasos y alcanza recompensa media positiva hacia el paso 10 000 en las dos semillas. Al final del entrenamiento la recompensa media es de 191,6 con la semilla 2026 (53 464 pasos, 6,3 h) y de 57,2 con la 2027 (27 929 pasos, 3,5 h). La diferencia

se debe a que la semilla 2027 se entrenó con episodios truncados a 225 pasos en lugar de 600. Sus 200 episodios suman menos pasos (unos 140 de media frente a 267) y su recompensa por episodio tiene un máximo más bajo, así que las dos curvas no son comparables en valor absoluto.

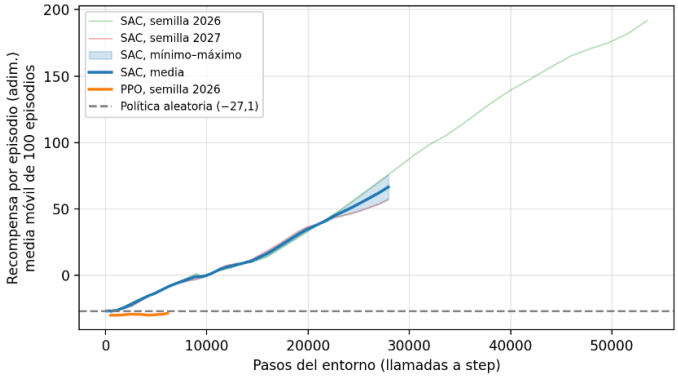


Figura 1. Recompensa por episodio frente a pasos del entorno, configuración de entrenamiento con el guía en modo variable (10–40). Cada curva es la media móvil de los últimos 100 episodios que registra Stable-Baselines3. La semilla 2027 se entrenó con episodios de 225 pasos y la 2026 con episodios de 600.

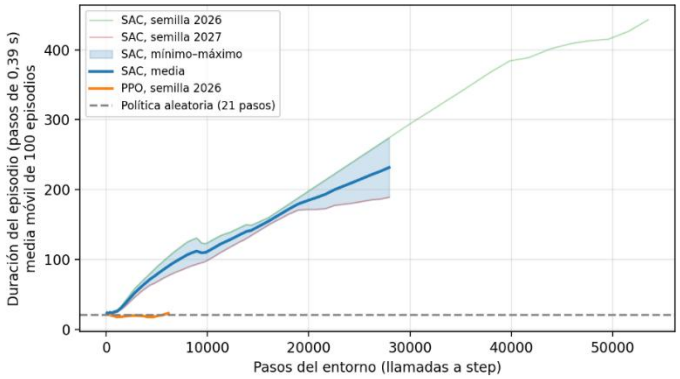


Figura 2. Duración media del episodio, en pasos de 0,39 s, frente a pasos del entorno. Mismas ejecuciones, semillas y ventana que la Figura 1.

La curva de recompensa tiene tres fases. Hasta el paso 2000 se mantiene en torno a −27, porque los primeros 250 pasos son aleatorios y los siguientes corresponden a una política con mucha entropía. Entre los pasos 2000 y 10 000 crece rápido: el agente aprende a mantener el blob a la vista y los episodios dejan de terminar a los pocos segundos. A partir de ahí la recompensa sigue subiendo de forma casi lineal, con un breve estancamiento en la semilla 2027 entre los pasos 12 400 y 13 600, y no llega a estabilizarse en ninguna de las dos semillas.

2.4. Entrenamiento con PPO y comparación con SAC

Con el mismo presupuesto de 200 episodios, PPO no se separa de la referencia aleatoria durante el entrenamiento. En el último registro, a los 6144 pasos y tras 1,2 h, la recompensa media es de −28,6 y la duración media de 23 pasos, prácticamente iguales a las de la política aleatoria (−27,1 y 21 pasos). SAC, en ese mismo número de pasos, ya estaba en −8,5.

La causa principal es la eficiencia en muestras. PPO es un algoritmo on-policy: recoge 512 pasos, unos 6 minutos de tiempo real con los reinicios, hace 10 épocas sobre ellos y los descarta. En todo el entrenamiento completó unas doce actualizaciones. SAC, en cambio, actualiza la red en cada paso reutilizando todas las transiciones del buffer, de modo que a los 6000 pasos ya había hecho unas 5700 actualizaciones.

Por estas razones se eligió SAC como algoritmo principal: cada paso del entorno cuesta tiempo real, y un algoritmo off-policy aprovecha cada transición muchas veces. en sus tres actualizacione

2.5. Evaluación determinista y selección de la política

La política seleccionada es la de SAC con semilla 2026: completa 4 de 5 episodios, obtiene la recompensa media más alta (302,6) y su único fallo llega en el paso 581, a 19 pasos del final. Cada modelo se evaluó en 5 episodios con la política determinista, sin acciones de arranque y con el guía en el mismo modo variable que en el entrenamiento. Estas cifras usan la recompensa y las condiciones de fin del propio entorno; las métricas del protocolo del Anexo B, medidas con la verdad del terreno, se presentan en el apartado 3.

Tabla 2. Evaluación determinista de los modelos, 5 episodios de hasta 600 pasos. El tamaño del blob es el normalizado en el último paso de los episodios completados; el objetivo es 0,20.

Modelo	Completados	Fallos	Recompensa media (desv.)	Duración media (pasos)	Tamaño final del blob
SAC, semilla 2026	4/5	1 blob perdido (paso 581)	302,6 (19,5)	596,2	0,13–0,19
SAC, semilla 2027	4/5	1 blob perdido (paso 290)	261,7 (76,7)	538,0	0,16–0,18
PPO, semilla 2026	5/5	—	230,5 (2,0)	600,0	0,07–0,09

Las dos semillas de SAC se comportan igual en los episodios completados: unos 0,5 de recompensa por paso, con el blob cerca del tamaño objetivo. La diferencia está en cuándo se produce el fallo. La semilla 2027 pierde al guía hacia la mitad de un episodio, lo que dispara la desviación de su recompensa, mientras que la 2026 lo pierde casi al final. En ambos casos el fallo es una pérdida del blob y nunca una colisión: la proximidad frontal se mantiene en 0,056, el valor de reposo de los infrarrojos.

PPO completa los 5 episodios, aunque durante el entrenamiento ninguno pasó de unos 20 pasos. Esto indica que la media de la política sí aprendió en sus doce actualizaciones una corrección básica del giro,

pero el ruido de exploración la ocultaba. Sin embargo, sigue al guía mucho más lejos de lo deseado: un tamaño de blob de 0,07–0,09, frente al 0,20 objetivo, lo que reduce su recompensa a unos 0,38 por paso. A esa distancia corre el riesgo de superar el umbral de 0,90 m de guía perdido del protocolo, y se trata de un único entrenamiento con muy pocas actualizaciones. Por eso no se elige como política final, aunque no haya fallado en estos 5 episodios.

2.6. Aplicación a las tres configuraciones y limitaciones

Se entrenó una única política, en modo variable con velocidades entre 10 y 40, y se aplica a las tres configuraciones del Anexo B sin reentrenar. El modo variable expone al agente a todo el rango de velocidades del guía y a sus frenadas en las curvas, de modo que C1 (crucero a 10) y C2 (crucero entre 10 y 40) son casos particulares de las situaciones vistas en el entrenamiento. C3 coincide con la configuración de entrenamiento y es, por tanto, la que mejor representa la Tabla 2

El estudio tiene tres limitaciones que conviene declarar:

- **Número de semillas.** La política final se ha entrenado con dos semillas, por debajo de las tres que se piden, ya que tuvimos problemas de conexión con el simulador con un ordenador.
- **Convergencia.** Ninguna de las curvas de SAC se estabiliza dentro de los 200 episodios, así que un entrenamiento más largo probablemente mejoraría el resultado, sobre todo en la pérdida ocasional del guía.
- **Duración real del paso.** El truncamiento por pasos se calculó suponiendo pasos de 0,2 s, pero la duración medida es de unos 0,4 s, así que los episodios de entrenamiento duran el doble de tiempo real de lo previsto. La evaluación del apartado 3 lo corrige midiendo los 120 s en tiempo real.

3. Métricas del protocolo del Anexo B

Evaluamos la política final (SAC, semilla 2026) de forma determinista, sin acciones de arranque y con las tres configuraciones del guía: C1 (crucero, 10–10), C2 (crucero, 10–40) y C3 (variable, 10–40). Fueron 5 episodios de 120 s de tiempo real por configuración (unos 300 pasos de 0,4 s), cada uno con un reinicio de la simulación y 7 s de espera del seguidor.

Desviaciones respecto al protocolo. No pudimos medir la separación con la verdad del terreno: un segundo contenedor del puente con el índice del guía no recibió ningún mensaje de sim/robot_location. Por eso usamos magnitudes de los sensores del seguidor, como permite el Anexo B justificándolo:

- **Guía perdido:** pelota sin detectar durante más de 3 s seguidos, como en el protocolo. El criterio de separación mayor que 0,90 m no puede comprobarse, y un alejamiento breve por encima de ese valor pasaría inadvertido.

- **Colisión:** proximidad frontal de los infrarrojos de al menos 0,85 o tamaño del blob de al menos 0,35, que son las condiciones de fin del entorno. No equivale a la separación menor que 0,12 m del protocolo.

- **Separación:** tamaño normalizado del blob, con banda objetivo [0,10, 0,30] (el tamaño objetivo 0,20 ± 0,10). No medimos la relación entre tamaño y distancia en metros, así que esta banda no equivale a la de 0,20–0,45 m del protocolo.
- **Desviación:** no se presenta en grados. La x del blob llega en una escala de 0 a 100 y no medimos el campo de visión de la cámara para convertirla; el error se descubrió muy cerca de la entrega. Lo que sí puede darse es la posición media de la pelota en la imagen: x = 57 sobre 100, ligeramente a la derecha del centro.

Tabla 3. Completados y desenlaces según el protocolo del Anexo B, por configuración y en conjunto. Separación y desviación medidas con los sensores del seguidor. La visibilidad se calcula sobre todos los pasos; el resto de columnas, sobre los pasos con la pelota visible.

Política	**Config.**	**Completados**	**Colisión**	**Guía perdido**	**Pelota visible (%)**	**Pasos en banda (%)**	**Tamaño medio**
SAC, semilla 2026	C1	5/5 (100 %)	0	0	99,6	89,6	0,154
SAC, semilla 2026	C2	5/5 (100 %)	0	0	99,9	89,2	0,155
SAC, semilla 2026	C3	4/5 (80 %)	0	1	98,3	86,7	0,150
SAC, semilla 2026	Total	14/15 (93 %)	0	1	99,3	88,6	0,153
Aleatoria	C1	0/5 (0 %)	0	5	45,9	38,5	0,084
Aleatoria	C2	0/5 (0 %)	0	5	42,7	28,6	0,079
Aleatoria	C3	0/5 (0 %)	0	5	49,4	31,0	0,082
Aleatoria	Total	0/15 (0 %)	0	15	46,0	32,8	0,082

La política completa todos los episodios en C1 y C2 y falla una vez en C3, por pérdida del guía a los 45,9 s. No se detectó ninguna colisión con los criterios del entorno. El único fallo apareció en C3; con solo 5 episodios por configuración, esa diferencia no permite concluir que C3 sea más difícil. Una explicación posible, no comprobada, es que en el modo variable el guía puede acelerar en cualquier punto, también al salir de una curva con la pelota cerca del borde de la imagen.

La política aleatoria no completa ningún episodio: los 15 terminan por pérdida del guía entre 4,3 y 12,3 s (10 a 30 pasos), coherente con la referencia del entrenamiento; al usar la misma semilla repite las mismas acciones y sus duraciones casi coinciden.

La política final mantiene la pelota visible en el 99,3 % de los pasos y dentro de la banda en el 88,6 %, frente al 46,0 % y el 32,8 % de la aleatoria. Su tamaño medio queda algo por debajo del objetivo: sigue al guía más lejos de lo previsto, de forma conservadora.

4. Conclusiones

SAC aprende a seguir al guía en modo variable en unos 10 000 pasos y, tras 200 episodios, completa 4 de cada 5 episodios de evaluación con el blob cerca del tamaño objetivo. PPO, con el mismo presupuesto, no llega a aprender durante el entrenamiento.

La recompensa fue muy importante, al premiar tener el blob a la vista se hizo que el robobo fuese premiado por aguantar más y más pasos. Los términos sobre el giro redujeron las oscilaciones, aunque no garantizan que el seguidor se mantenga en su carril, que no es observable.

Los fallos que quedan son siempre pérdidas del guía, nunca colisiones. La política ha aprendido a no acercarse demasiado, pero aún no recupera bien la pelota cuando la pierde en una curva.

4.2. Problemas encontrados

- **Coste en tiempo real.** Un entrenamiento de 200 episodios llega a 6,3 h, lo que limitó el número de semillas y de variantes que se pudieron probar.
- **Duración del paso.** El paso real dura unos 0,39 s en lugar de los 0,2 s previstos, porque tras la espera de la acción hay que esperar un mensaje nuevo del detector de blobs (5 Hz). Esto alarga los episodios de 600 pasos a unos 4 minutos.
- **Falta de registros.** No se guardaron modelos ni registros de las versiones intermedias del entorno, de modo que su evolución solo puede describirse de forma cualitativa.
- **Normalización de la x del blob.** El detector entrega la x del blob en una escala de 0 a 100, pero el entorno la normalizaba como si fueran píxeles de 0 a 320. La política aprendió igualmente, porque la observación sigue siendo monótona con la posición de la pelota, pero el término de centrado de la recompensa tenía su máximo alcanzable en el borde derecho de la imagen

4.3. Transferencia al entorno real

El entorno se diseñó para que la política pueda ejecutarse en el robot real sin reentrenar. La observación usa solo el detector de blobs, normalizado por el tamaño de la imagen y el área máxima, y las

velocidades ordenadas en el paso anterior. Ningún dato del módulo sim entra en la observación ni en la recompensa. Todos los parámetros que dependen de la calibración están en follow_city_config.py.

4.4. Mejoras propuestas

- Entrenar más pasos y con al menos tres semillas, ya que las curvas no se habían estabilizado.
- Corregir la normalización de la x del blob (escala de 0 a 100) y reentrenar, para que el término de centrado premie de verdad la pelota centrada.